

# 基于深度学习卷积神经网络的地震波形自动分类与识别

赵明<sup>1</sup>, 陈石<sup>1</sup>, David A Yuen<sup>2,3</sup>

(1. 中国地震局地球物理研究所, 北京

2. 美国哥伦比亚大学应用物理和应用数学系, 纽约, 10027

3. 中国地质大学大数据学院, 武汉, 430074)

**摘要:** 发展高效、高精度、普适性强的自动波形拾取算法在地震大数据时代背景下显得越来越重要。波形自动拾取算法的主要挑战来自如何适应不同区域的不同类型地震事件的分类与挑选。本文针对地震事件-噪音分类这一问题, 使用 13839 个汶川地震余震事件建立数据集, 应用深度学习卷积神经网络(CNN)方法进行训练, 并用 8900 个新的汶川余震事件作为检测数据集, 其训练和检测准确率均达到 95%以上。在对连续波形的检测中, CNN 方法在精度和召回率上优于 STA/LTA 和 Fbpicker 传统方法, 并能找出大量人工挑选极易遗漏的微震事件。最后, 我们应用训练好的最优模型对选自全国台网的 441 个台站 8 天的连续波形数据进行了识别、到时挑取及与参考地震目录关联, CNN 检出 7016 段波形, 用自动挑选算法拾取到 1380 对 P,S 到时, 并与 540 个地震目录事件成功关联, 对 1 级以上事件总体识别准确率为 54%, 二级以上为 80%, 证明了 CNN 模型具有泛化能力, 初步展示了 CNN 在发展兼具效率、精度、普适性算法, 实时地震监测等应用上具有巨大潜力。

**关键词:** 卷积神经网络, 自动波形拾取

## Waveform classification and seismic recognition by convolution neural network

Zhao Ming<sup>1</sup>, Chen Shi<sup>1</sup>, David A Yuen<sup>2</sup>

(1 Institute of Geophysics, China Earthquake Administration, Beijing 100081, China

2. University of Minnesota, USA

3. China University of Geoscience, wuhan, 430074, China)

**Abstract:** The development of efficient, high-precision, and universal automatic waveform pick-up algorithm is more and more important in the background of earthquake big data. The main challenge comes from how to adapt to the classification of different types of seismic events in different regions. In this paper, according to the seismic event-noise classification problem, a convolutional neural network method was used to train the dataset based on 13839 Wenchuan earthquake aftershocks and 8900 new Wenchuan aftershock events were used as the test data set. The training and detection accuracy rates were both over 95%. In the detection of continuous waveforms, the CNN method is superior to the traditional methods of STA/LTA and Fbpicker in precision and recall rate, and can find a large number of manually selected microseismic events that are easily missed. Finally, we use the trained optimal model to identify 8-day continuous waveform data from 441 stations nationwide. CNN detects 7016 waveforms, then we pick up 1380 pairs of P and S arrival times using an automatic picking algorithm, finally the pick-ups were successfully associated with 540 earthquake catalog events. The overall recognition accuracy of events above magnitude 1 was 54% and 80% above magnitude 2, while in some areas such as Sichuan and Xinjiang the detection rate is higher. It is shown

**基金项目** 国家自然科学基金(41774090, 41804047)和中国地震局地球物理研究所基本科研业务专项 DQJB1801 为本研究提供资助。

**作者简介** 赵明, 男, 博士, 助理研究员, 主要从事地震学方面的研究, Email: mzhao@cea-igp.ac.cn

**通讯作者** 陈石, 男, 研究员, 主要从事地球内部物理学研究, Email: chenshi@cea-igp.ac.cn

that CNN neural network has broad application prospects in the real-time earthquake detection and location.

**Key Words:** convolutional neural network (CNN), waveform auto-picking

## 0 引言

随着地震仪在全球范围的大规模部署,人类已经进入地震大数据时代。如何处理地震网络每天收集的大量数据,特别是从质量参差不齐的连续波形记录中分离出地震和噪声是一个非常棘手的问题。例如:大地震发生之后,抗震救灾与应急救援需要对余震序列进行动态的监测与快速定位,地震编目,地球内部速度结构研究如层析成像等都是以大量地震事件的挑选与到时拾取作为基础,而目前这些工作仍主要靠低效的人工完成(Fang et al., 2015)。

为了解决这一问题,多年来人们发展了各种自动地震识别算法,比较典型的有:基于振幅的长短窗、基于 Akaike 信息准则(Akaike information criteria, 简称 AIC)的方法(Akaike, 1974),以及基于波形相似性的波形自相关、互相关、指纹和相似性阈值法。各种方法都有自己的优势和局限性:长短窗法用短时平均(Short-Term Average, STA)和长时平均(Long-Term Average, LTA)之比来反映信号振幅、频率等的变化,当地震信号到达时,STA/LTA 值会有一个突变,当其比值大于某一个设定阈值时,则判定有地震事件发生,这种方法计算快速,对于脉冲、信噪比高的信号识别准确率较高,但会漏掉低信噪比的信号(Allen, 1978; Withers et al., 1998; Trnkoczy, 2012); AIC 方法,依据 AIC 寻求波形曲线的极小点作为震相的到时点,包括自回归 AIC 方法(Sleeman and Van Eck, 1999; Akazawa, 2004)、基于峰度的 Kurtosis-AIC 方法(Küperkoch et al., 2010)以及基于小波变换的 wavelet-AIC 方法(Zhang et al., 2003)等,该类方法对震相和频率的变化十分敏感,常被用于震相到时的精确拾取,然而,与 STA/LTA 类似, AIC 的结果也强烈依赖于信噪比以及检测区间;波形相关性(或称模板匹配)分析可以用来检测源自单个区域具有相同的震源机制的地震,对于重复发生的地震检测十分有效,然而,其检测精度很大程度上取决于使用的模板数量,此外随着模板数据库的增长,计算量也呈指数级增加(Skoumal et al., 2014);指纹和相似性阈值法(简称 FAST)使用了结合计算机视觉技术和大数据处理方法的 Waveprint 音频指纹算法,对波形进行特征提取,将每个波形浓缩成一个只保留其主要特征的紧凑“指纹”,使用局部敏感哈希算法降低相似性搜索量,该方法在检测灵敏度、适用性、计算效率方面都有不错的表现,但内存和计算开销较大(Yoon et al., 2015)。

神经网络算法是指旨在模拟人类大脑学习过程的一类算法,它利用彼此互联的非线

性“神经元”组成的复杂网状结构，可以模拟输入特征集合（如地震波形）与预期输出值（如震相类型，到时等）之间复杂的非线性关系，并能进一步对新的输入特征给出有效预测（Goodfellow et al., 2016）。类似于模板匹配，神经网络算法需要事先从大量样本学习不同地震波形的特征，但其独特优势在于训练好的模型具有泛化能力，可以发现训练集不包含的新特征。早在上世纪 90 年代，就有人将人工神经网络引入到地震波形自动识别中来（Wang and Teng, 1995; Zhao and Takano, 1999; Gentili and Michelini, 2006），由于早期的神经网络均为全连接层，受限于当时的计算水平，很难构建深层网络，其发展受到很大限制。2010 年以后，随着大数据时代的到来，以及计算机性能的进一步提高，神经网络算法的发展迎来新的契机。其中以卷积神经网络的广泛应用最具代表性：卷积神经网络通过共享权重，比人工神经网络参数更少，可构建的网络层数更深，提取特征的能力大大提高，在语音识别、视觉识别、自然语言处理等多个领域，都取得了前所未有的突破（Krizhevsky et al., 2012; LeCun et al., 2015; He et al., 2016）。与这些问题类似，地震事件的识别本质上也是一个特征提取与参数优化的问题：首先经过大量预设样本的训练，不断更新优化神经元的权重和偏重参数，使得损失函数（用于衡量模型输出值与真实值之间的差异）最小，最终得到保存了不同地震与噪声样本特征的模型，应用这一最优模型就可以对全新的数据进行特征识别。近几年来，卷积神经网络已经在地震事件检测方面得到了一系列应用：孔庆开等（Kong et al., 2016）利用人工神经网络区分智能手机网络收集的加速度波形中的地震信号与人类活动噪声；Perol 等（2018）应用卷积神经网络对俄克拉荷马地区的连续记录波形进行了识别与定位；Ross 等（2018）基于南加州地区的 273,882 多个地震事件建立数据集并训练 CNN 模型，其得到的模型具有较强的泛化能力，即使对与训练数据所属区域构造不同的地区，如日本 Kumamoto 地震的事件波形，也能有效检测。

本研究以汶川地震之后四川及邻区 14 个台站 7-8 月期间手动挑选的 13839 条和 8900 条地震事件波形分别构建训练数据集和测试集，搭建深度卷积神经网络进行模型训练和测试。训练好的 CNN 模型不仅在连续波形识别上精度和召回率优于传统方法，而且能够有效识别大量人工挑选遗漏掉的小震事件，其检测灵敏度、适用性、计算效率等综合性能相比传统方法有了很大的提升。

## 1 CNN 方法及性能对比

### 1.1 数据收集与数据预处理

2008 年 5 月 12 日汶川 8.0 级地震发生以后，余震非常频繁，其震级分布面广（0~6.6

级不等），以 0.5~3 级的小震居多，同时前人对该区进行了大量的研究，积累了充分的余震目录和到时拾取资料，这些资料具有很高的可信性，为本研究利用 CNN 网络地震波形识别提供了必要的训练数据和检验手段。

首先，深度学习需要收集大量样本数据。数据样本太少会导致模型识别能力的缺陷，同时易造成过拟合。理想的数据集的每一类别都需要充分的样本数量，并且能够覆盖地震波形所具有的各种复杂特征。我们的数据集来源于四川及邻区 14 个中国地震台网固定台站 7-8 月间的连续波形记录，分事件和噪声两类。在事件类方面，从 8 月连续波形中截取 13839 个事件波形片段，作为训练数据，从 7 月连续波形记录中截取 8900 个事件波形片段作为测试数据，所有事件波形均取 P 到时前 5s 至 S 到时后 10s；在噪声类方面，采用排除掉事件波形之后随机筛选截取。数据集所有样本均统一为 30s 数据（长度不足的以零值填充，长度超过的从尾部截断）。此外为尽可能减少事件人工标注和噪声随机筛选带来的误差，我们手动对数据集进行了清洗，更正较为明显的标注错误。

为了增加数据量，我们还对清洗后的数据集进行了增强操作。由于地震三分量波形可以看作一维三通道图像数据，我们参照图像识别，采用了如下几种常用的数据增强方式：平移、加噪（模糊处理）、滤波。平移是指我们以 P、S 到时为中心，在 $[-3s, +3s]$ 时间窗内沿时间轴滑窗，对震相位置进行微调处理；加噪是指对波形的每个采样点进行随机扰动，本研究采用高斯噪声扰动；滤波是指我们对波形使用 $[0, 20\text{Hz}]$ 的带通滤波。通过上述操作，我们将事件样本数量扩展到 65000 个，为下一步训练模型打好了基础。

图 2 展示了数据预处理前后不同的训练和损失函数曲线，可以看出用处理后的数据集算法能更快收敛，而且我们将预处理之后的数据集时间戳列表放在 <https://github.com/mingzhaochina/dataset>，供大家测试使用。大家可先向中国地震台网中心提交连续波形数据申请，并根据时间戳自行截取波形建立数据集。

## 1.2 CNN 网络结构

在用于地震-噪声分类的 CNN 网络结构上，参考了在手写数字分类问题上取得成功的经典卷积神经网络“Le-Net5”（LeCun et al., 2015）。如图 1 所示，其中卷积层的功能在于提取特征，池化层通过降采样过滤掉一些特征。与手写数字图像分类的二维卷积不同，地震波形采用一维卷积，其卷积核为 3，通道数为 32。训练数据按批次输入，3000×3 张量，对应于 30s 长三分量波形，经过逐层特征提取与过滤，到第八层时减为 12×32，并一维化为 384 个特征，经过全连接层之后使用 ReLU 激活函数计算每一类的概率，并与预先设置的分类阈值比对，低于阈值则对应“0”标签（噪声），高于阈值则

为对应于“1”标签（地震）。




图 1 卷积神经网络结构。

Fig.1 The structure of convolutional neural network.

### 1.3 CNN 算法性能表现

在所用的算法方面，我们使用了 L2 正则化以及随机梯度下降算法来最小化交叉熵损失函数，并用 ADAM 优化算法以及可变时间步长，进一步提高了计算效率，使得我们的算法在上也能快速运行。在深度学习训练中，将所有数据迭代完一遍称为一个 epoch，本研究使用 Tensorflow 程序(<https://www.tensorflow.org>)，在一块 GTX 1080ti GPU 卡训练 10 个 epoch（约 40000 步迭代）只需要 20 分钟，其训练达到的最高精度为 98.2%，在验证集上对 8900 个样本的识别仅需不到 20 秒，其验证精度最高达到 94.4%（图 2）。CNN 方法的计算效率介于传统方法（STA/LTA，AR-AIC 等）与模板匹配之间，前者仅需数分钟且无需 GPU 计算，后者往往需要几百甚至数千 GPU 计算机时，可参见 Perol 等（2018）。




图 2 数据预处理前后的训练过程:

(a) 训练曲线;(b)交叉熵损失函数曲线。

Fig.2 Different train process before and after data preprocessing:

(a)train curve;(b)cross-entropy loss function curve.

## 2 连续波形检测

### 2.1 连续波形检测对比实验

我们将在训练集和测试集上精度最高的 CNN 模型用于连续波形检测，并与经典 STA/LTA 算法（Krischer 等，2015）和 fbpicker 算法（Chen and Holland,2016）的识别效果对比。所用数据为四川台网 MXI 台一个月连续波形（2008.8.1-9.1），并以该时间段专家手动挑选的 1901 个事件波形作为参照。我们用精度  $P$  和召回率  $R$  来衡量不同算法的识别效果（下标  $e$  和  $n$  分别代表事件和噪声），其定义为：

$$P_e = T_p / (T_p + F_p)$$

$$R_e = T_p / (T_p + F_n)$$

其中， $T_p$  为真正例，即算法识别的事件是真实事件，反之则为假正例  $F_p$ ； $T_n$  为真反例，即算法识别的噪声是真实噪音，反之则为假反例  $F_n$ 。精度高说明误检率低，召回率高则证明算法漏检率低，只有二者同时都高算法或模型才具有实用价值。表 1 列出了三种方法各自的精度和召回率。其中 CNN 网络识别出 3763 个事件波形，其中有 1803 个与参照样本相符。传统算法在精度和召回率上均低于 CNN 方法。

表 1 CNN 与 Fbpicker、STA/LTA 算法对比

Table 1 The comparison of CNN、Fbpicker and STA/LTA algorithm

方法	$P_e$	$R_e$	$T_p$	$F_p$	$F_n$
CNN	47.9%	94.5%	1803	1960	98
STA/LTA	29%	85%	1615	3954	286
fbpicker	36%	88%	1672	2972	229

需要指出的是，作为参照的专家样本大多经过多台震相关联，定位等后续处理，其准确度很高，但由于人眼识别的主观性和局限性，完整性未必很高（例如很容易漏掉孤立事件和信噪比低的微震事件），而已有研究表明，CNN 模型的一大优势在于能够有效识别微震。因此严格意义上来讲，这里的精度 $P_e$ 并不能完全反映 CNN 算法的分类效果。如图 3 所示，以 2008 年 8 月 25 日 MXI 台一日的连续波形识别为例，这一日共有 43 个专家挑选事件，但进一步的甄别我们发现该日可能还存在约 230 个震幅较弱的微震事件，应用 CNN 方法可以更好地识别这些微震（图 3b），如果将这些微震考虑进去，则经过计算，算法的精度和召回率大约在 73%和 62%左右，同时 CNN 方法还可以通过将误分类波形代入数据集重新训练，从而获得越来越好的实际分类效果。

★

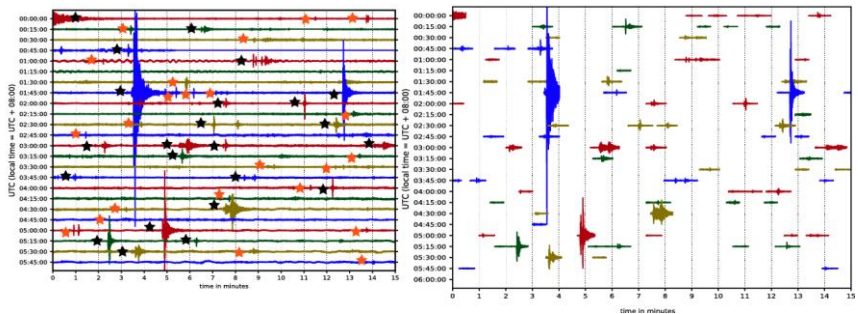


图 3 CNN 连续波形检测与专家样本示例：(a) 红色星表示专家挑选事件，黄色星表示专家遗漏的微震事件；(b) CNN 算法识别的事件片段。

Fig 3 An example of CNN continuous waveform detection and the expert selected events: (a) Black stars indicate the experts selected events, yellow stars indicate micro-seismic events missed by experts;(b) CNN detections.

## 2.2 全国台站连续波形自动识别

以上我们通过模型训练、验证、连续波形检测三个阶段，证明了 CNN 算法和模型具备对复杂地震波形的强大分类能力。为了进一步检验 CNN 模型对不同地域的连续地震波形的泛化能力，我们将该模型尝试用于全国台网连续波形的记录。我们一共采用了 441 个台站的连续波形（仪器工作正常，数据质量较好），其分布遍布全国，时间为 2017 年

12月11日-19日期间。此外，由于不同的区域具有不同地质构造背景，其事件波形也各不相同，因此我们参考历史地震活动性区域划分（图4a），按照地震震中之间的欧几里得距离进行了K-Means聚类(图4b)，将441个台站的事件波形划分为9类（对应9个区域），检验CNN算法性能与地域的相关性。

我们的识别方法如下：

1. 应用长短窗方法，根据各地台站的信噪比条件选择合适的阈值（在大部分情况下阈值 $>5$ ）做初步筛选，这样做是为了提高算法效率，过滤掉大部分环境噪声；
2. 将筛选出的波形片段用预训练好的CNN网络识别；
3. 对CNN网络识别为地震的波形片段，我们进一步采用dbshear震相自动识别程序进行挑取，该方法的流程是：首先进行P波震相的挑取，然后使用偏振能量分析将地震波水平分量上的P波能量去除，再使用STA/LTA进行S波初拾取，最后应用kurtosis函数法进行S震相的准确拾取（参见Ross et al.,2016）；
4. 我们将拾取到的P、S到时与中国地震台网发布的参考地震目录进行关联：首先利用一维速度模型计算理论参考到时，最后将理论到时与拾取P、S到时进行比较， $<2s$ 的被认为是正确识别。

应用以上方法，CNN网络检出7016段波形，用方法检测到1380对P,S到时，并与540个地震目录事件成功关联。中国地震台网目录在这一时间段共记录1级以上地震事件1073个，二级以上246个，经过比较，我们的方法对1级以上事件总体识别准确率为54%（图4b），二级以上为80%（图4c）。



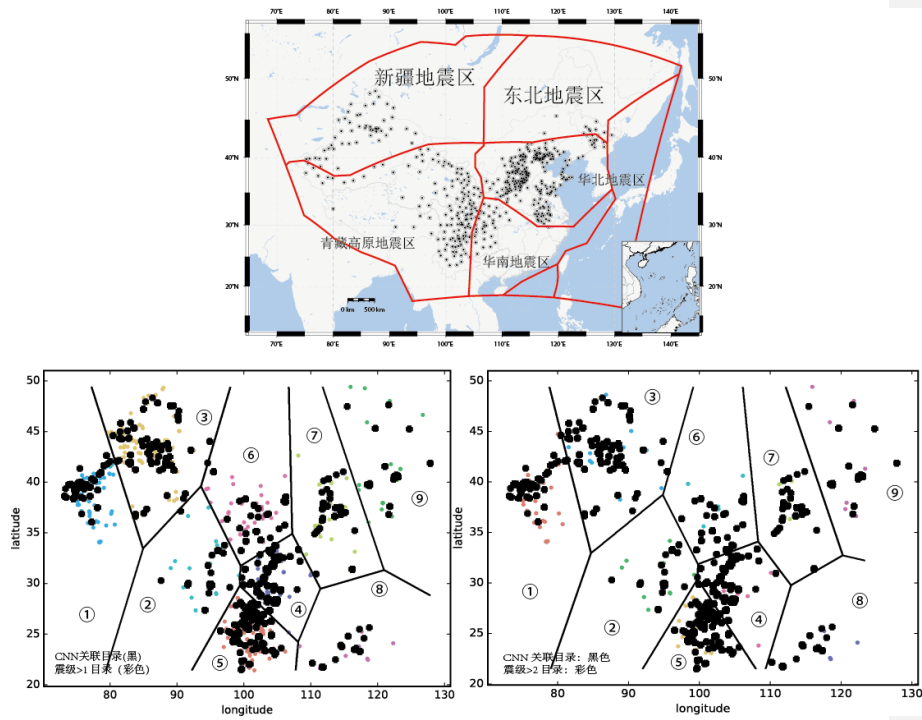


图 4 台站与地震震中分布:

(a) 441 个台站分布; (b) >1 级震中分布, 彩色代表各省局地震目录的定位结果, 黑色为 CNN 识别后再定位结果; (c) >2 级震中分布。

Fig 4 Distribution of stations and earthquakes:

(a) Distribution of 441 stations; (b) > 1 level epicenter distribution, color represents the location result from the earthquake catalogue of each provincial bureau, black is the result of CNN identification and relocation; (c) those of > 2 epicenter distribution.

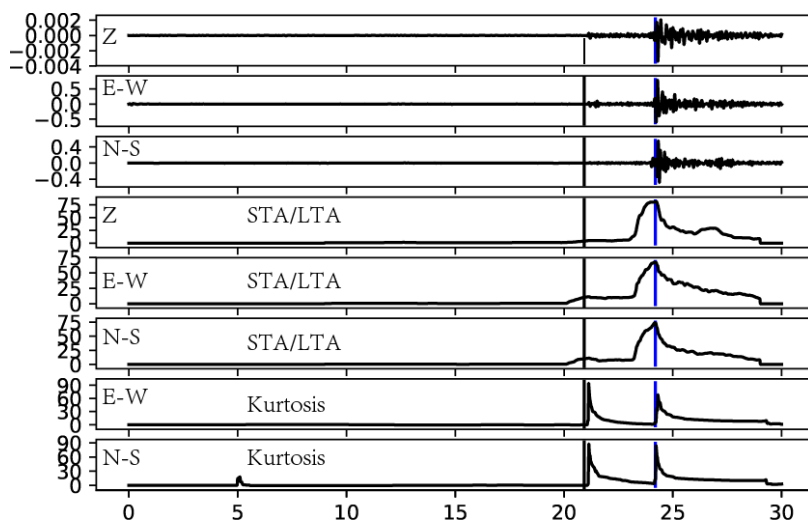



图 5 对 CNN 识别的地震事件进行 P（红线），S 震相（蓝线）自动挑取。  
Fig 5 P (red line) and S phase (blue line) are automatically picked up for the seismic events identified by CNN.

### 2.3 地域分析

从地域统计来看，④⑤（大致位于川滇地区）、①③（大致位于新疆地区）、⑦（华北地区）与参考目录匹配较好，其余地区较差（表 2）。我们推测这可能与我们的训练数据大量采用了汶川地震的余震波形有关。以上地区均为我国地震多发区域，除了大震强震，3 级以下的小震微震活动也非常频繁，我们的模型对于识别这些地区的微震小震特别有效。

表 2 全国实时流 CNN 事件识别结果

Table 2 CNN events identification of the national real-time data stream.



### 3 讨论与分析

地震学是一门数据驱动的科学，从海量原始波形数据中分离出地震信号是地震目录产出的第一步，因此也是地震学研究的基础。与基于单一或多个特征函数的传统方法相比，CNN 网络的精度和召回率（误检和漏检率）相比传统算法有非常明显的提升（降低），并且训练好的模型具有非常稳定的输出能力，不需要根据不同信噪比水平的数据频繁调整阈值。与模板匹配、FAST 等严格基于波形相似性的方法不同，CNN 神经网络从训练数据中提取的是抽象特征，这意味着模型具有更强的泛化能力，能够与更多样的波形特征相匹配，所以 CNN 往往能够检测到新的地震类型，这也是深度学习方法的主要优势所在。在第四节中我们基于汶川余震数据训练的 CNN 网络，对地质构造背景不同①③⑦的也具有较强的泛化能力，便是这种能力的证明。

尽管 CNN 展示了其在地震波形识别领域良好的应用前景，目前来看，仍具有以下局限性：首先，作为一种监督学习方法，神经网络对于训练样本的依赖性较强，如果缺乏大量预设样本，或是预设样本过于单一，无法涵盖所分类对象所具有的一般特征，则很容易导致模型过拟合或根本无法训练；其次，大量正负样本的标注十分棘手，并且很难用统一标准评判，因此，即使训练好的模型能在测试集上达到很高的精度，其最终质量好坏往往只能通过实际应用检验，在实际应用中我们经常遇到这样的情况：有些 CNN 误识别的波形，使用长短窗或自回归方法甚至肉眼都可以轻松识别，因此在实际应用中应该设置某种投票机制，将基于不同原理的多种方法结合起来，才

能取得最佳的识别效果；最后，目前 CNN 等深度学习算法背后的原理尚不清楚，尽管已经在地震学领域得到一系列应用，但不同学者提出的不同神经网络结构均是通过反复试错之后取得，其依据是模型在训练和测试集上的表现而不是基于对算法本身的理解，因此很多模型放到实际应用中都会出现“性能瓶颈”，即精度和召回率在到达一定程度后很难继续提升，而我们很难分清这到底是由于训练数据样本分布的不足，还是模型设计本身存在缺陷。

#### 4 结论和展望

本研究通过搭建 CNN 深度神经网络模型，建立数据集进行模型训练、验证与实际波形检测，证明了 CNN 网络的强大复杂特征分类能力可以推广应用于地震波形分类这一应用场景。同时，在训练样本数量不够大的情况下，我们对数据集采用了平移、加噪和滤波等增强操作来扩大训练样本，对防止模型过拟合，增强模型容错能力起到了一定作用。对不同地质构造背景区域的波形识别，则证明了我们基于余震数据训练的 CNN 网络，对其他构造区域也具有泛化能力。

根据深度学习在其他领域的应用经验，其优势主要在于处理多分类问题。由于地震的复杂性，其波形可能呈现多种形态，很难用地震-噪音这样的简单二分类问题囊括。因此，如何建立一个包含不同地震类型（例如近震、远震；天然地震、爆破、塌陷、滑坡、核爆等）、每一类具有充足样本数量的大型数据集是一个非常繁重的任务。在下一步工作中，我们将增加来自不同地域、不同构造类型的地震和噪声样本，根据样本的特征不同做更进一步分类，同时应用更深层的网络进行训练，获得不但能够识别地震信号，还能推断地震类型的神经网络模型，使得地震数据的检测与识别更加智能化。

#### 致谢

感谢地震局球所房立华研究员协助提供人工挑选数据，感谢天池余震识别 AI 大赛平台提供连续波形数据。感谢中国地震局第二监测中心提供部分台站实时数据，以及长安大学孙少波老师、球所张贝博士为实时数据流下载提供帮助。文中部分图件采用 GMT 程序绘制，特此感谢 GMT 中文社区（<https://gmt-china.org>）。感谢加州理工的 Zachary Ross 博士提供的 dbshear 程序作为对比。Fbpicker 程序来自 <https://github.com/austinholland/PhasePApy>。

#### 参考文献（Reference）

Akaike H. 1974. A new look at the statistical model identification. *IEEE Transactions on Automatic Control*, 19(6): 716-723, doi: 10.1109/TAC.1974.1100705.

Akazawa T. 2004. A technique for automatic detection of onset time of P-and S-Phases in strong motion records. //13th World Conference on Earthquake Engineering. Vancouver B C, Canada: International Association for Earthquake Engineering.

批注 [w1]: 本条文献在正文中未被引用

批注 [a2]: 已经引用

Allen R V. 1978. Automatic earthquake recognition and timing from single traces. *Bulletin of the Seismological Society of America*, 68(5): 1521-1532.

Chen C, Holland A A. 2016. PhasePapy: A robust pure python package for automatic identification of seismic phases. *Seismological Research Letters*, 87(6): 1384-1396, doi: 10.1785/0220160019.

Fang L H, Wu J P, Wang W L, et al. 2015. Aftershock observation and analysis of the 2013  $M_s$  7.0 Lushan earthquake. *Seismological Research Letters*, 86(4): 1135-1142.

Gentili S, Michelini A. 2006. Automatic picking of P and S phases using a neural tree. *Journal of Seismology*, 10(1) 39-63, doi: 10.1007/s10950-006-2296-6.

Goodfellow I, Bengio Y, Courville A, et al. 2016. Deep Learning. The MIT Press. (请核对文献类型)

He K M, Zhang X Y, Ren S Q, et al. 2016. Deep residual learning for image recognition. //2016 IEEE Conference on Computer Vision and Pattern Recognition. Las Vegas, NV, USA: IEEE.

Küperkoch L, Meier T, Lee J, et al. 2010. Automated determination of P-phase arrival times at regional and local distances using higher order statistics. *Geophysical Journal International*, 181(2): 1159-1170.

Kong Q K, Allen R M, Schreier L, et al. 2016. Myshake: A smartphone seismic network for earthquake early warning and beyond. *Science Advances*, 2(2): e1501055, doi: 10.1126/sciadv.1501055.

Krischer L, Megies T, Barsch R, et al. 2015. ObsPy: A bridge for seismology into the scientific Python ecosystem. *Computational Science & Discovery*, 8(1): 014003, doi: 10.1088/1749-4699/8/1/014003.

Krizhevsky A, Sutskever I, Hinton G E. 2012. Imagenet classification with deep convolutional neural networks. //Advances in Neural Information Processing Systems, 1097-1105. (未找到出版信息, 请补充)

LeCun Y, Bengio Y, Hinton G. 2015. Deep learning. *Nature*, 521(7553): 436-444.

Perol T, Gharbi M, Denolle M. 2018. Convolutional neural network for earthquake detection and location. *Science Advances*, 4(2): e1700578, doi: 10.1126/sciadv.1700578.

Ross Z E, White M C, Vernon F L, et al. 2016. An improved algorithm for real-time S-wave picking with application to the (augmented) ANZA network in southern California. *Bulletin of the Seismological Society of America*, 106(5): 2013-2022, doi: 10.1785/0120150230.

Ross Z E, Meier M A, Hauksson E, et al. 2018. Generalized seismic phase detection with deep learning. *Bulletin of the Seismological Society of America*, 108(5A): 2894-2901, doi: 10.1785/0120180080.

Skoumal R J, Brudzinski M R, Currie B S, et al. 2014. Optimizing multi-station earthquake template matching through re-examination of the Youngstown, Ohio, sequence. *Earth and Planetary Science Letters*, 405: 274-280.

Sleeman R, Van Eck T. 1998. Robust automatic P-phase picking: An on-line implementation in the analysis of broadband seismogram recordings. *Physics of the Earth and Planetary Interiors*, 113(1-4): 265-275.

Tmkoczy A. 2012. Understanding and parameter setting of STA/LTA trigger algorithm. //Bormann P ed. New Manual of Seismological Observatory Practice 2 (NMSOP-2). Potsdam: Deutsches GeoForschungsZentrum GFZ.

Wang J, Teng T L. 1995. Artificial neural network-based seismic detector. *Bulletin of the Seismological Society of America*, 85(1): 308-319.

Withers M, Aster R, Young C, et al. 1998. A comparison of select trigger algorithms for automated global seismic phase and event detection. *Bulletin of the Seismological Society of America*, 88(1): 95-106.

Yoon C E, O'Reilly O, Bergen K J, et al. 2015. Earthquake detection through computationally efficient similarity search. *Science Advances*, 1(11): e1501057, doi: 10.1126/sciadv.1501057.

Zhang H, Thurber C, Rowe C. 2003. Automatic P-wave arrival detection and picking with multiscale wavelet analysis for single-component recordings. *Bulletin of the Seismological Society of America*, 93(5): 1904-1912.

Zhao Y, Takano K. 1999. An artificial neural network approach for broadband seismic phase picking. *Bulletin of the Seismological Society of America*, 89: 670-680.

批注 [a3]: 这是一本书

批注 [w4]: 本条文献在正文中未被引用

批注 [a5]: 已经引用

批注 [a6]: 该篇文章是会议论文, Advances in Neural Information Processing Systems 是会议名称

